

Compte Rendu de Projet

SAE821 – Gérer un projet

Rapport de présentation de la modélisation d'un système de
recommandation respectant la vie privée

Pegliasco Matteo
Berge Enzo
Audouard Florian
Hermelin Lois
Master Informatique et Mathématiques
Université de Toulon, La Garde, Var, France

Table des matières

1	Recherches théoriques	2
1.1	Systèmes de recommandation	2
1.1.1	Comprendre les Systèmes de Recommandation	2
1.1.2	Filtrage collaboratif	4
1.1.3	Factorisation de matrice	5
1.2	Système de recommandation à froid	5
1.3	Confidentialité	6
1.3.1	Chiffrement homomorphe	6
1.3.2	Differential privacy	6
2	Démarche choisie	7
2.1	Motivations du choix	7
2.1.1	Confidentialité des données	7
2.1.2	Analyse du bruit Laplacien	8
2.1.3	Models de recommandations	8
2.2	Implémentation dans le système	9
2.3	Limites et perspectives	9
3	Résultats expérimentaux	9
3.1	Précision des recommandations	9
3.2	Performances computationnelles	9
3.3	Mesure de la confidentialité	9
3.4	Résumé	9
	Annexes	10

Introduction

Ce rapport technique est un compte rendu dans le cadre de la SAE821 dont l'objectif est la conception et la modélisation d'un système de recommandation respectueux de la vie privée des utilisateurs. Les systèmes de recommandation sont aujourd'hui omniprésents dans de nombreux domaines, notamment sur les plateformes de commerce en ligne, les réseaux sociaux ou encore les services de streaming. Ils permettent d'orienter les utilisateurs vers des contenus pertinents en se basant sur l'analyse de leurs comportements et préférences. Cependant, pour la majorité, ce traitement massif de données personnelles soulèvent des problématiques importantes liées à la protection de la vie privée, l'intégrité et la sécurité des données. Il est donc essentiel de réfléchir à des solutions techniques permettant de préserver la confidentialité des données tout en maintenant l'efficacité des recommandations. L'objectif de ce projet est de modéliser un système de recommandation de films prenant en compte tout ces critères, en utilisant des méthodes préservant la protection des données utilisateurs. Ce rapport présentera les différentes étapes de la modélisation, les choix techniques réalisés, ainsi que les méthodes mises en œuvre pour concilier personnalisation et respect de la vie privée.

1 Recherches théoriques

1.1 Systèmes de recommandation

1.1.1 Comprendre les Systèmes de Recommandation

Les systèmes de recommandation sont devenus des outils incontournables au fil du temps. Ils permettent aux utilisateurs d'être dirigé vers des contenus pertinents et personnalisés parmi une multitude de choix, en s'appuyant sur des données comportementales, des préférences et des connaissances du contexte. Cette recherche retrace l'évolution des approches de recommandation, de leurs fondements les plus simples à des méthodes d'intelligence artificielle avancée, en s'appuyant sur l'article : Delving Deeper into Recommender Systems: From Basics to State-of-the-Art.

Evolution Chronologique

- Années 1990 - Premiers Modèles :

Le Filtrage Collaboratif (CF) repose sur l'idée que des utilisateurs ayant partagé des préférences similaires dans le passé auront probablement des préférences semblables à l'avenir. Il existe deux variantes :

- **User-based CF** : recherche des utilisateurs similaires à l'utilisateur cible pour recommander les objets qu'ils ont aimés.
- **Item-based CF** : recherche des objets similaires à ceux déjà aimés par l'utilisateur pour proposer des recommandations

Filtrage basé sur le Contenu (CB) s'appuie uniquement sur les comportements passés de l'utilisateur, en particulier ses interactions avec certains objets. Contrairement au CF, il ne tient pas compte de la communauté mais des caractéristiques des éléments.

- Années 2000 - Hybridation et Deep Learning :

Modèles hybrides Ces modèles combinent CF et CB pour bénéficier de leurs avantages respectifs et une amélioration du démarrage à froid.

Début de l'apprentissage profond L'arrivée du deep learning a introduit une nouvelle manière de représenter utilisateurs et objets à l'aide de réseaux de neurones capables d'extraire des caractéristiques complexes, non linéaires et profondes.

- Années 2010 - Contexte et Connaissances :

Les systèmes de **context-aware** prennent maintenant en compte des informations telles que le temps, la localisation, le dispositif utilisé ou encore l'état émotionnel.

Les systèmes **knowledge-bases**, eux, utilisent des bases de connaissance et des bases de règles explicites pour mieux cerner les besoins utilisateurs, particulièrement utiles dans des cas de niches où les données sont rares.

- Années 2020 - Intelligence Renforcée et Explicabilité :

La Recommandation par Apprentissage par Renforcement (RL) permet une approche séquentielle et interactive. Le système apprend à adapter ses recommandations en fonction des réactions de l'utilisateur. L'algorithme explore l'espace des solutions pour améliorer ses retours.

La Recommandation Explicable fournit une justification compréhensible à l'utilisateur, améliorant ainsi la confiance et la transparence

Types de Systèmes de recommandation :

- **Basé sur la mémoire** : Filtrage collaboratif simple
- **Basé sur un modèle** : Factorisation de matrice, réseaux de neurones, SVD
- **Basé sur le contenu** : utilisation des attributs des objets
- **Modèles hybrides** : Combine le filtrage collaboratif et filtrage basé sur le contenu
- **Apprentissage profond** : Réseaux de neurones
- **Système Contextuels** : Tiennent compte du contexte d'utilisation
- **Basé sur les connaissances** : Utilisent des logiques de règles, des bases de fait et ontologies
- **Apprentissage par renforcement** : Tiennent compte d'une interaction avec le client
- **Explicabilité** : Fournit une approche plus transparentes
- **Multimodalité** : Combine plusieurs types de données
- **Protection de la vie Privée** : Utilise des techniques pour définir une forme de protection des résultats de requêtes

Méthodes Avancées :

1. **Filtrage Collaboratif avec ALS** (Alternating Least Squares) : Repose sur le fait que deux utilisateurs ayant eu des opinions similaires auront des opinions similaires dans d'autres situations. Utilise la factorisation de matrice avec une méthode d'optimisation par moindres carrés alternés.

2. **Singular Value Decomposition (SVD)** :

Utilisation d'une matrice de notes $R = (\text{utilisateur} * \text{items})$, la SVD la décompose comme :
 $R \approx U \cdot \Sigma \cdot V^t$

- U = matrice des facteurs latents utilisateur
- Σ = matrice diagonal des valeurs singulières
- V^t = transposé de la matrice des facteurs latents des items

SVD version recommandation :

Factorisation de la Matrice $\hat{R}_{ui} = P_u^T Q_i$

R_{ui} = note prédite par l'utilisateur u pour l'item i

P_u = vecteur latent de l'utilisateur u (préférences)

Q_i = note vecteur latent de l'item i (caractéristiques)

Le produit scalaire donne la note prédite de u donnerait à i .

Apprentissage de P et Q :

$$\min_{P, Q} \sum_{(u, i) \in K} (R_{ui} - P_u^T Q_i)^2 + \lambda (\|P_u\|^2 + \|Q_i\|^2)$$

Avec K l'ensemble des paires utilisateur-item connues (données d'entraînement), R_{ui} note réelle et λ le coefficient de régularisation

3. **Recurrent Neural Network (RNN)** :

Le réseau de neurones permet de traiter des séquences (texte, audio, clics, utilisations ...) Il possède une mémoire interne (qui utilise l'info précédente à chaque étape) et gère les dépendances temporelles.

À chaque instant (t), le RNN reçoit une entrée (x_t) et un état caché précédent (h_{t-1}), puis il calcule :

- L'État caché : $h_t = \tanh(W_h h_{t-1} + W_x x_t + b)$
- La Sortie : $y_t = \text{softmax}(W_y h_t + b_y)$

Avec :

- h_t = état caché (mémoire interne) à l'instant t
- x_t = entrée à l'instant t
- y_t = sortie prédite à l'instant t
- W_h, W_x, W_y = matrices de poids
- b, b_y = biais

- tanh = fonction d'activation
- softmax = utilisée pour une prédiction de classe

4. ConvNet (CNN) :

Modèle de traitement spation de données (image, audio, vidéos) :

- **Convolutions** : Extraction de caractéristiques locales
- **Pooling** : Reduction dimensionnelle
- **Fattening** : Prise de décision finale

5. Multi-Armed Bandit :

Approche d'apprentissage par renforcement, visant à maximiser les gains et explorer l'espace d'action tout en exploitant les meilleures options (permet de recommander tout en testant de nouvelles options).

1.1.2 Filtrage collaboratif

Le filtrage collaboratif est une méthode de recommandation qui repose sur l'exploitation des interactions passées entre les utilisateurs et les objets. Contrairement au filtrage basé sur le contenu, il ne nécessite aucune information sur les caractéristiques des objets recommandés.

Fonctionnement

1. **Collecte de données** : Récupération des interactions entre utilisateurs et objets, sous forme explicite (notes, avis) ou implicite (clics, temps passé, etc.).
2. **Construction de la matrice utilisateur-objet** : Création d'une matrice où les lignes représentent les utilisateurs, les colonnes les objets, et les cellules contiennent les interactions.
3. **Mesure de similarité** : Calcul de la similarité entre utilisateurs (user-based) ou entre objets (item-based) à l'aide de fonctions telles que la similarité cosinus ou le coefficient de corrélation de Pearson.
4. **Prédiction** : Estimation de la préférence d'un utilisateur pour un objet non encore évalué, en se basant sur les préférences des utilisateurs ou objets similaires.
5. **Génération de recommandations** : Sélection des objets les plus susceptibles d'intéresser l'utilisateur cible.

Exemple illustratif Considérons la matrice suivante représentant les notes de films par trois utilisateurs :

	Film A	Film B	Film C	Film D
Utilisateur 1	5	?	4	2
Utilisateur 2	4	3	5	1
Utilisateur 3	2	4	1	5

Ici, le système peut prédire la note que l'utilisateur 1 donnerait au *Film B*, en se basant sur les préférences des utilisateurs 2 et 3, jugés similaires selon leurs comportements passés.

Avantages

- **Pas besoin de métadonnées** : Il peut fonctionner sans connaître les caractéristiques des objets à recommander.
- **Recommandations personnalisées** : Il permet de proposer des contenus pertinents et parfois inattendus grâce à l'analyse des préférences collectives.
- **Adaptabilité** : Le système évolue avec les comportements des utilisateurs, ce qui le rend dynamique.

Inconvénients

- **Problème du démarrage à froid (cold start)** : Difficile de faire des recommandations précises pour un nouvel utilisateur ou un nouvel objet sans historique d'interactions.
- **Sparsité des données** : Les matrices utilisateur-objet sont souvent très clairsemées, ce qui complique la détection de similarités fiables.
- **Dépendance au comportement collectif** : Il peut recommander des objets peu pertinents si les utilisateurs similaires ont des goûts trop différents ou incohérents.

Applications

- **Divertissement** : Netflix, Spotify pour recommander des films ou de la musique.
- **E-commerce** : Amazon pour proposer des produits selon les comportements d'achat d'utilisateurs similaires.
- **Éducation** : Recommandation de cours ou ressources pédagogiques.
- **Réseaux sociaux** : Suggestion de contacts, contenus ou groupes.

1.1.3 Factorisation de matrice

La factorisation de matrice [8] est une technique de recommandation user-based qui approxime les préférences des utilisateurs par le produit de deux matrices de plus faible dimension. Ces matrices représentent des caractéristiques latentes des utilisateurs et des items — ici, les films. Comme évoqué précédemment, cette approximation peut être obtenue à l'aide de l'algorithme des moindres carrés alternés ou de la descente de gradient stochastique. Cette méthode est particulièrement adaptée aux systèmes de recommandation car elle s'applique efficacement à de grands ensembles de données, gère bien la sparsité des notations, et peut être étendue pour intégrer des informations supplémentaires (comme des métadonnées ou du contenu).

Par exemple :

Considérons une matrice de notes R représentant les notes données par 2 utilisateurs à 4 films :

$$R = \begin{bmatrix} 5 & 3 & 0 & 1 \\ 4 & 0 & 0 & 1 \end{bmatrix}$$

où R_{ij} est la note donnée par l'utilisateur i au film j , et représente une note manquante.

L'objectif de la factorisation est donc d'approcher R par le produit de deux matrices : $R \approx U \cdot V$. En partant de deux matrices de tailles arbitraire et en corrigeant les erreurs, on peut obtenir une approximation de la matrice de notes R comme :

$$R \approx \begin{bmatrix} 1.5 & 0.5 \\ 1.2 & 0.4 \end{bmatrix} \cdot \begin{bmatrix} 3.0 & 1.5 & 0.5 & 0.2 \\ 1.0 & 1.0 & 0.2 & 0.5 \end{bmatrix} = \begin{bmatrix} 5.00 & 2.75 & 0.85 & 0.55 \\ 4.00 & 2.20 & 0.68 & 0.44 \end{bmatrix}$$

Avec cette factorisation, la méthode prédit alors que l'utilisateur 1 donnerait une note proche de 0.85 au troisième film et l'utilisateur 2 donnerait une note proche de 0,2.

Toutefois, cette approche présente certaines limites. Tout d'abord, elle nécessite une étude profonde de ses hyperparamètres pour obtenir des résultats pertinents, notamment le nombre de facteurs latents à utiliser. De plus, elle est sensible au problème du démarrage à froid pour les nouveaux utilisateurs ou items -films dans le cas présent- et a un coût de calcul qui peut devenir important selon la taille du jeu de données.

1.2 Système de recommandation à froid

Au fil du temps, plusieurs approches ont été développées pour répondre aux problèmes de recommandation à froid, c'est-à-dire lorsqu'il s'agit de recommander de nouveaux films ou de faire des suggestions à de nouveaux utilisateurs. Parmi elles, on peut distinguer les principales suivantes :

- **Les méthodes basées sur le contenu (content-based)**, comme présenté par Schein, A. I., Popescul, A., Ungar, L. H., et Pennock, D. M. (2002) [2], utilisent les caractéristiques des items — ici, des films — comme la description, le genre ou les acteurs. En calculant la similarité entre les caractéristiques de films (par exemple avec la similarité cosinus), on peut recommander des films proches de ceux déjà appréciés par un utilisateur.
- **Les approches hybrides** combinent le filtrage collaboratif et le filtrage basé sur le contenu afin de bénéficier des avantages des deux. Par exemple et comme présenté par Xiaoyuan Su et Taghi M. Khoshgoftaar (2010) [4], plusieurs implémentations sont possibles. Il est possible d'implémenter séparément une méthode collaborative et une méthode basée sur le contenu, puis de combiner les résultats pour générer des recommandations plus pertinentes ou encore d'implémenter un modèle unifié, intégrant à la fois des caractéristiques du contenu et du filtrage collaboratif. L'ajout progressif d'interactions utilisateur permet ainsi d'améliorer la précision des recommandations.

- **Les méthodes basées sur le clustering** regroupent les utilisateurs ou les items selon leurs caractéristiques communes, comme présenté par Nguyen et al. (2024)[14] ou encore Snider (2019) [7]. L'objectif de cette approche est de générer des recommandations en s'appuyant sur la structure des groupes formés en recommandant, par exemple, un unique cluster de données pour limiter la diversité ou inversement en recommandant des films de plusieurs clusters pour la favoriser.

1.3 Confidentialité

1.3.1 Chiffrement homomorphe

Le chiffrement homomorphe est une technique de cryptographie qui permet d'effectuer des calculs sur des données chiffrées sans avoir besoin de les déchiffrer au préalable mais dont le résultat déchiffré conserve les opérations entre les données claires. Pour cela, plusieurs catégories de chiffrements existent :

- **Chiffrement partiellement homomorphe** : Il permet de réaliser des opérations sur des données chiffrées pour une loi spécifique, par exemple l'addition ou la multiplication entre des données chiffrées.
- **Chiffrement presque entièrement homomorphe** : Il permet de réaliser un nombre limité d'opérations sur des données chiffrées pour plusieurs lois spécifiques, par exemple l'addition et la multiplication entre des données chiffrées, à cause d'une accumulation de bruit.
- **Chiffrement entièrement homomorphe** : Il permet de réaliser un nombre illimité d'opérations sur des données chiffrées pour toutes les lois possibles, mais il est limité par la taille du bruit accumulé lors des opérations.

Dans le cadre de ce projet nous nous sommes intéressés particulièrement au chiffrement entièrement homomorphe pour sa flexibilité d'utilisation pour différents systèmes de recommandations.

Ainsi, plusieurs approches existent pour la mise en place du chiffrement homomorphe :

- **Chiffrement DGHV avec bootstrapping [11]** : Le chiffrement DGHV [9] est un système de chiffrement homomorphe, opérant sur des entiers, basé sur le problème de la somme de sous-ensembles clairsemée et le problème du PGCD approché.
- **Chiffrement GSW avec bootstrapping[11]** : Le chiffrement GSW [10] est un système de chiffrement homomorphe, opérant sur des bits, basé sur le problème de la factorisation des entiers et le problème du logarithme discret.
- **Chiffrement TFHE** : Le chiffrement TFHE [13] est un système de chiffrement homomorphe, opérant sur des bits, basé sur la version torique du problème Learning With Errors.

Toutefois, même si le chiffrement homomorphe permet de préserver la confidentialité des données, leurs utilisations présentent plusieurs contraintes :

- Les données chiffrées sont généralement plus volumineuses que les données claires, ce qui peut poser des problèmes de stockage et de transmission de données. Par exemple, dans l'article de I. Chillotti, N. Gama, M. Georgieva, et M. Izabachène. (2016) [6] où on apprend en conclusion de l'article que la taille du texte chiffré est 400 000 fois plus grand que celui d'origine.
- L'utilisation de "bootstrapping" [11] pour limiter l'accumulation de bruit peut augmenter le temps de calcul avec un nombre d'opérations significatives réalisées. En effet, servant de contrôle de la taille
- du bruit, les opérations de "bootstrapping" augmentent les opérations réalisées sur le texte chiffré, pouvant ainsi influencer sur le temps de calcul. augmentent aussi le temps de calcul.
- La mise en place sans ressources externes est complexe et les ressources externes - sans prendre en compte leurs fiabilités - sont principalement disponibles avec des bibliothèques en C++ ou RUST, comme Microsoft SEAL, HELib ou PALISADE, ce qui complique l'interaction avec d'autres langages de programmation comme JAVA.

1.3.2 Differential privacy

La confidentialité différentielle est une approche qui vise à garantir la protection de la vie privée des individus dans les ensembles de données en restreignant la relation entre les données de sortie et les données

de l'utilisateur. Pour cela, plusieurs approches existent :

- **Mécanisme exponentiel** : Le mécanisme exponentiel [12] permet de sélectionner aléatoirement un élément parmi un ensemble de données, en favorisant les éléments ayant le plus de poids selon une fonction d'évaluation donnée.
- **Réponse aléatoire** : Le mécanisme de réponse aléatoire telle qu'utilisé dans le bulletin de psychologie écrit par de BEGIN G. et SAVARD F. [1] vise à brouiller les réponses données en remplaçant aléatoirement certaines réponses par des valeurs aléatoires. En connaissant la probabilité d'obtenir une valeur aléatoire, il est alors possible d'estimer la proportion de données réelles ainsi que la variance au sein des données.
- ***K-anonymisation* et *L-diversité*** : La *K-anonymisation*[3] et la *L-diversité* consistent à masquer les éléments de quasi-identification d'un individu en le regroupant avec $K - 1$ autres individus dans une représentations plus large, tout en conservant la visibilité des L informations spécifiques à chaque utilisateurs et destinées à être partagées.
- **Mécanisme de Laplace ou Gaussien** : Le mécanisme de Laplace ou Gaussien [5] consiste à altérer les données des utilisateurs pour masquer les données réelles tout en conservant la répartition moyenne des données en ajoutant un bruit aléatoire.

2 Démarche choisie

2.1 Motivations du choix

2.1.1 Confidentialité des données

Le cadre de ce projet est de mettre en place un système de recommandation de films respectant la vie privée des utilisateurs. Nous avons considéré que la base de données des utilisateurs ainsi que les films proposés pouvaient évoluer au fil du temps. Pour la protection de la vie privée des utilisateurs, nous avons considéré l'utilisation du chiffrement homomorphe TFHE, mais la complexité de son implémentation et de son utilisation, avec notamment l'interaction entre différents langages de programmation (JAVA, C++, RUST), ainsi que la complexité de l'utilisation de l'apprentissage machine avec une bibliothèque spécialisée, nous a poussés à nous intéresser davantage à la confidentialité différentielle.

Plus précisément, nous nous sommes particulièrement intéressés à la mise en place du mécanisme de bruitage et du mécanisme exponentiel pour la mise en place de la confidentialité différentielle pour, respectivement, les recommandations pour un nouvel utilisateur et les recommandations personnalisées d'un utilisateur ayant déjà évalué une certaine quantité de films. En ce qui concerne le mécanisme de génération du bruit, nous avons choisi d'utiliser le mécanisme de Laplace pour masquer les données des utilisateurs. Ce choix est motivé par le contexte de ce projet. En effet, les utilisateurs peuvent modifier leur évaluation d'un film. Dans cet optique, et contrairement au mécanisme gaussien, nous avons favorisé le mécanisme de Laplace car c'est un mécanisme ϵ -indistinguable. C'est-à-dire qu'il garantit qu'une modification d'une entrée dans une base de données crée une modification bornée de la distribution de probabilité. De plus, étant donné que la base de données initiale possède relativement peu d'évaluation utilisateurs pour chaque film, le mécanisme de Laplace est privilégié puisque la génération de bruit à forte valeur est moins probable que pour le mécanisme gaussien, dû à une distribution plus centré en 0 pour la courbe Laplacienne, ce qui permet de garantir une meilleure précision dans l'étude de la moyenne des évaluations des films.

Enfin, dans le cadre d'une protection des données privée des utilisateurs, nous avons eu la volonté de limiter l'utilisation de ressources externes pour la génération des données bruitées afin de reposer au minimum sur la fiabilité de ces ressources et avoir un maximum de contrôle sur la génération de bruit (c.f Analyse du bruit Laplacien). Ce faisant, l'implémentation du mécanisme Gaussien impliquerait l'implémentation complexe, avec le temps disponible, de l'approximation de l'inverse de la fonction :

$$F(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt \quad (1)$$

afin de générer du bruit. Ainsi, nous avons privilégié l'implémentation plus simple du mécanisme de Laplace qui s'adapte mieux aux traitements ponctuels sur des bases de données de taille variable, correspondant aux besoins de notre système d'entraînement pour nos recommandations. En complément, et comme présenté précédemment, nous avons considéré l'utilisation du mécanisme exponentiel pour une

sélection aléatoire biaisée d'un film recommandé. Cette approche permet à la fois de favoriser certains films - ici ceux qui ont une note moyenne la plus éloigné de 2.5 pour recommander des films qui n'ont jamais été noté ou des films avec une bonne notation - grâce à une fonction d'utilité définie dans le système, tout en limitant le risque que l'utilisateur puisse extraire des informations individuelles sur les autres utilisateurs ayant permis de générer les recommandations avec une bonne calibration.

2.1.2 Analyse du bruit Laplacien

Comme présenté plus tôt,

2.1.3 Models de recommandations

Pour le système de recommandation, nous avons choisi de mettre en place deux approches pour la recommandation de films : un système se basant sur le SVD pour un individu connu par le système - individu ayant déjà noté un certain nombre de films - et un autre système de recommandation basé sur le clustering non supervisé pour la recommandation à froid pour un nouvel utilisateur.

- Pour le SVD
- Pour le système de clustering :

Le système de recommandation mis en place se base sur une recommandation item based via un système de clustering, à l'image de Snider 2019 [7] et de la sélection aléatoire de films. Plus précisément, Le système de clustering Pour ce faire, l'algorithme de recommandation se compose en trois étapes principales :

1. Sélection des films pouvant être recommander selon certains critères. Dans notre implémentation, les films recommandables sont les films ayant une note moyenne supérieure ou égale à un seuil (ici, 3) ou ayant un nombre d'évaluations inférieur ou égal à un seuil (ici, 0). Cette approche permet alors de recommander des films étant globalement appréciés par les utilisateurs l'ayant noté et donc de recommander des films qui pourront plaire à l'utilisateur mais aussi de recommander des films peu notés pour obtenir plus d'informations statistiques sur ces films tout en favorisant la diversité des films recommandés.
2. Clustering des films : Une fois nos films sélectionnés, des vecteurs de caractéristiques sont générés à partir de leurs informations descriptives. Ici, nous avons utilisé les genres et le synopsis des films ainsi que leurs dates de sortie (année, jour et mois) pour générer un vecteur de caractéristiques. Pour générer le vecteur de caractéristiques des genres, respectivement du synopsis, dans le serveur python, nous avons utilisé la fonction "MultiLabelBinarizer" de la bibliothèque "sklearn", respectivement la fonction "SentenceTransformer" de la bibliothèque python "sentence_transformers". Après la normalisation de ces vecteurs, une réduction de dimension est appliquée (via l'algorithme UMAP) suivie d'un clustering non supervisé (DBSCAN) comme présenté dans L'utilisation de l'algorithme DBSCAN permet ainsi de regrouper les films selon leur similarité - ici, la similarité cosinus - tout en offrant une meilleure adaptation à l'évolution des films dans la base de données que des clusters supervisés.
3. Sélection aléatoire de films : Afin de favoriser la diversité des films recommandés, le système sélectionne aléatoirement un cluster, puis, de manière biaisée pour favoriser les films les moins notés, un film au sein de celui-ci. Pour ce faire, nous avons utilisé une fonction d'utilité définie dans le système pour favoriser les films ayant une note moyenne la plus proche de 0, qui après le tri de l'étape 1, représente les films les moins notés.

L'objectif de ce système de recommandation vise donc, à la fois, de représenter la diversité des films dans la base de données, limiter la redondance des recommandations avec les choix aléatoires de clusters et de films, mais aussi de recommander des films ayant un certain intérêt, ici les films appréciés en moyenne par les utilisateurs ou les films peu notés (car possiblement récent ou peu vu).

2.2 Implémentation dans le système

2.3 Limites et perspectives

films peu noté depuis extrêmement longtemps : doit être bizarre

3 Résultats expérimentaux

3.1 Précision des recommandations

3.2 Performances computationnelles

3.3 Mesure de la confidentialité

3.4 Résumé

Références

- [1] J.-P. Rolland, « La technique de la réponse aléatoire : un moyen de contrôler la désirabilité sociale dans la mesure de l'estime de soi », *Bulletin de Psychologie*, vol. 33, no. 343, 1979. [En ligne]. Disponible : https://www.persee.fr/doc/bupsy_0007-4403_1979_num_33_343_1128 [Consulté le 28 mai 2025].
- [2] A. I. Schein, A. Popescul, L. H. Ungar, et D. M. Pennock, « Methods and Metrics for Cold-Start Recommendations », in *Proc. 25th Annu. Int. ACM SIGIR Conf. Res. Dev. Inf. Retr. (SIGIR '02)*, 2002, pp. 253–260. [En ligne]. Disponible : https://www.researchgate.net/publication/221300490-Methods_and_Metrics_for_Cold-Start_Recommendations [Consulté le 28 mai 2025].
- [3] Wikipedia, « K-anonymisation », 2006. [En ligne]. Disponible : <https://fr.wikipedia.org/wiki/K-anonymisation> [Consulté le 28 mai 2025].
- [4] X. Su et T. M. Khoshgoftaar, « A Survey of Collaborative Filtering Techniques », *IEEE Trans. Knowl. Data Eng.*, vol. 22, no. 1, pp. 107–117, 2010. [En ligne]. Disponible : <https://pages.stern.nyu.edu/~atuzhili/pdf/TKDE-Paper-as-Printed.pdf> [Consulté le 28 mai 2025].
- [5] C. Dwork et A. Roth, *The Algorithmic Foundations of Differential Privacy*, Found. Trends Theor. Comput. Sci., vol. 9, no. 3–4, pp. 211–407, 2014. [En ligne]. Disponible : <https://www.cis.upenn.edu/~aaroth/Papers/privacybook.pdf> [Consulté le 28 mai 2025].
- [6] I. Chillotti, N. Gama, M. Georgieva, et M. Izabachène, « Faster Fully Homomorphic Encryption : Bootstrapping in Less Than 0.1 Seconds », *Cryptology ePrint Archive*, Rapport 2016/870, 2016. [En ligne]. Disponible : <https://eprint.iacr.org/2016/870> [Consulté le 28 mai 2025].
- [7] G. Snider, « Unsupervised Product Clustering : Exploring the Cold Start Problem », *SSENSE Tech Blog*, Medium, 2019. [En ligne]. Disponible : <https://medium.com/ssense-tech/unsupervised-product-clustering-exploring-the-cold-start-problem-8053ef04bac9> [Consulté le 28 mai 2025].
- [8] E. Azar, « Deep Dive into Matrix Factorization for Recommender Systems : From Basics to Implementation », Medium, 2020. [En ligne]. Disponible : <https://medium.com/@eliasah/deep-dive-into-matrix-factorization-for-recommender-systems-from-basics-to-implementation-79e4f> [Consulté le 28 mai 2025].
- [9] E. Goblé et R. Gatelier, « Le chiffrement DGHV », Université de Technologie de Compiègne. [En ligne]. Disponible : https://www.utc.fr/~wschon/sr06/tx_chiffrement_homomorphe/pages/dghv.html [Consulté le 28 mai 2025].
- [10] E. Goblé et R. Gatelier, « GSW », Université de Technologie de Compiègne. [En ligne]. Disponible : https://www.utc.fr/~wschon/sr06/tx_chiffrement_homomorphe/pages/vecteurs_propres_approx.html [Consulté le 28 mai 2025].
- [11] E. Goblé et R. Gatelier, « Le Bootstrap », Université de Technologie de Compiègne. [En ligne]. Disponible : https://www.utc.fr/~wschon/sr06/tx_chiffrement_homomorphe/pages/bootstrapping.html [Consulté le 28 mai 2025].
- [12] *Programming Differential Privacy*, « Chapter 9 — Fully Homomorphic Encryption (FHE) ». [En ligne]. Disponible : <https://programming-dp.com/ch9.html> [Consulté le 28 mai 2025].

- [13] B. Chandran, A. Ghoshal, S. Halevi, S. Ranellucci, et N. P. Smart, « Faster Homomorphic Comparison Operations for BGV and BFV », *Cryptology ePrint Archive*, Rapport 2023/958, 2023. [En ligne]. Disponible : <https://eprint.iacr.org/2023/958> [Consulté le 28 mai 2025].
- [14] Q. Nguyen, M. Naghiaei, et Y. Zhang, « Cold-start Recommendation by Personalized Embedding Region Elicitation », *arXiv preprint* arXiv :2406.00973, 2024. [En ligne]. Disponible : <https://arxiv.org/abs/2406.00973> [Consulté le 28 mai 2025].

Annexes

Données supplémentaires, résultats détaillés, ou code pertinent.